这里的代码版本管理使用的是 git 进行管理，地址为 https://github.com/841194253/DL_class/tree/master/exam_latest/exam_LRX

邮箱为 liryi6677@foxmail.com,欢迎老师提供修改优化意见。

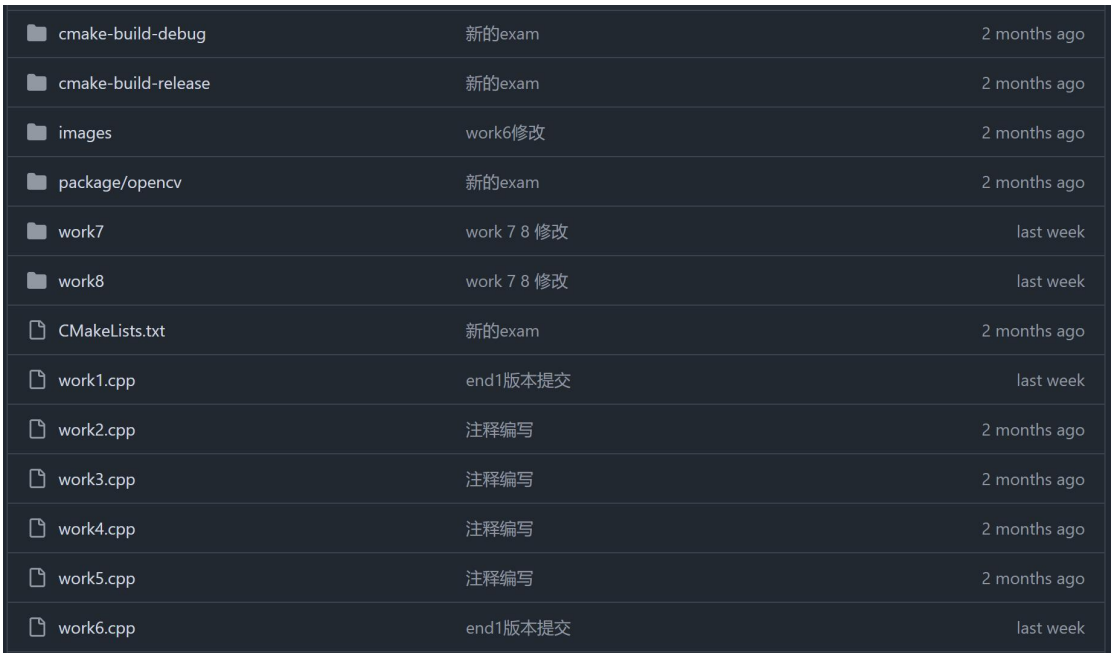

cmake-build-debug	新的exam	2 months ago
cmake-build-release	新的exam	2 months ago
images	work6修改	2 months ago
package/opencv	新的exam	2 months ago
work7	work 7 8 修改	last week
work8	work 7 8 修改	last week
CMakeLists.txt	新的exam	2 months ago
work1.cpp	end1版本提交	last week
work2.cpp	注释编写	2 months ago
work3.cpp	注释编写	2 months ago
work4.cpp	注释编写	2 months ago
work5.cpp	注释编写	2 months ago
work6.cpp	end1版本提交	last week

这里用 cpp 来完成作业 1-6，这里用的是 Clion 作为 ide，编译环境为 MinGW，用 CMake 来作为编译脚本，Opencv 的版本为 4.10.0，cpp 版本为 C++11

一、提取图中的植物部分，并估算植物的绿色部分面积，已知植物生长的槽的宽是 20 cm。

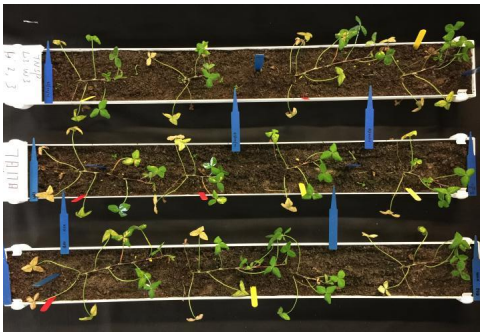

读取图像，转换图像至 HSV 色彩空间，便于分离绿色区域，定义绿色的 HSV 范围，通过 cv::inRange 生成绿色掩码,使用形态学操作（开闭运算）去除小噪声和孔洞，得到绿色区域掩码，通过 cv::countNonZero 统计绿色像素数，依据槽宽 20 cm 和图像宽度计算每像素对应的实际面积，估算绿色部分总面积

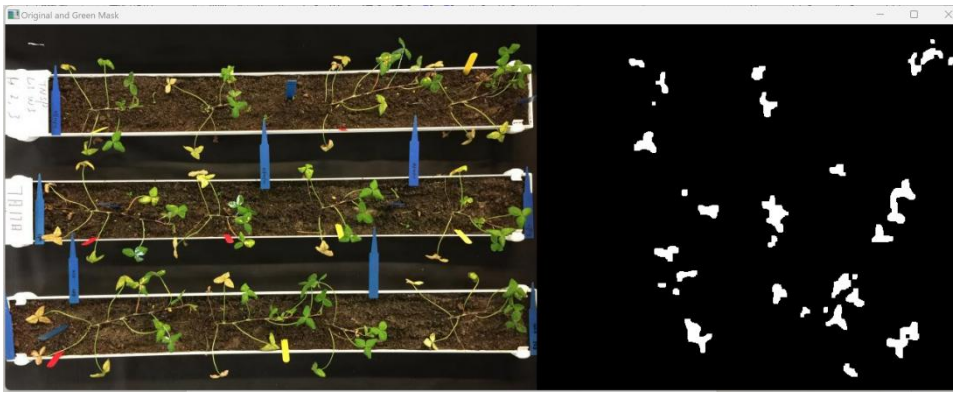

绿色面积为 10.6847 平方厘米

具体代码详见 work1.cpp

二、提取图像中的叶片病害的图斑数目、估算病害图斑占叶片的总面比例。

读取叶片图像转换为 HSV 颜色空间，定义黄色区域的 HSV 范围，用 cv::inRange 生成病害掩码图，使用形态学操作（闭运算）去除噪声和孔洞，清理掩码区域，转换原图为灰度图，统计非零像素数，作为叶片总面积，统计掩码中非零像素数，作为病害区域面积计算病害面积占比：(病害面积 / 叶片总面积) × 100%

比例为 1.36698%

具体代码详见 work2.cpp

三、采用图像形态学获取图像中小米的粒数、每粒小米的最大投影面积或者外接最大正方形的长与宽。

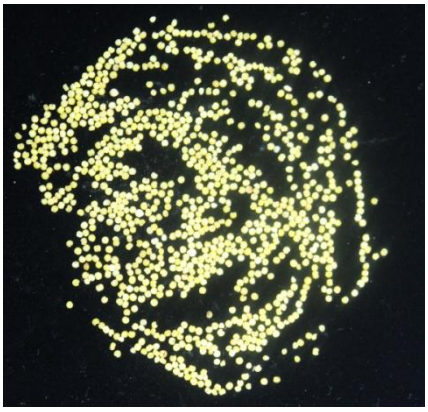

读取图像并转换为灰度图，通过固定阈值或自适应阈值，将图像转化为二值图，突出小米颗粒并抑制背景，使用 cv::findContours 检测小米颗粒的轮廓，遍历轮廓，计算每颗颗粒的面积，过滤小面积噪声，在原图上绘制外接框，以便直观验证结果。

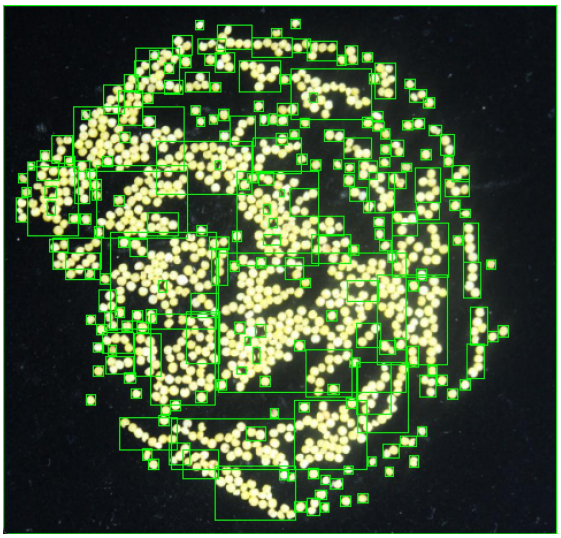

数量为 309

具体代码详见 work3.cpp

四、分割获取谷子的各叶片，即把每个叶片独立分割，并用不同颜色表示。

读取输入图像并转化为灰度图像，通过高斯模糊平滑图像，减少噪声对边缘检测的干扰，使用 Canny 算法检测图像中的边缘，使用 cv::findContours 获取每片叶片的轮廓。直接展示结果。

具体代码详见 work4.cpp

五、还原图中被部分遮挡的苹果

遮挡苹果　　还原苹果

读取目标图像并显示，创建与图像同尺寸的空白掩码，用于标记需要修复的区域，鼠标拖动绘制修复区域，实时更新原图和掩码，使用修复算法 INPAINT_TELEA 来进行平滑处理

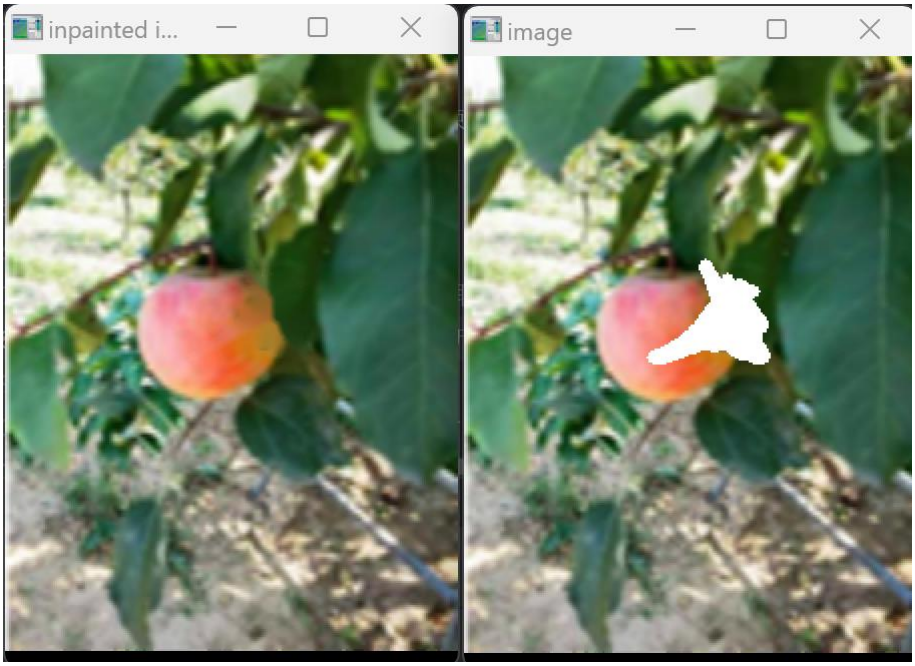

具体代码详见 work5.cpp

六、采用直方图均衡方法处理图像 A，结果类似图 B。

图 原始图（左图）和直方图均衡方法处理后图像（右图）

读取图像，转换为灰度图，转化为 CV_8UC1，进行高斯模糊，直方图均衡化，锐化图像

具体代码详见 work6.cpp

作业 7、8 用 cpp 写过于复杂，libtorch 太难用了，这里使用 keras2 的库，用 tensorflow 来进行训练，keras 为 2.10.0，tensorflow 为 2.10.0，均使用 cudnn 进行加速，其余的库版本，详见 requirements.txt

七、利用 LSTM 模型预测一个时间序列数据的未来趋势。

这里我选择了美国疾病控制和预防中心每周流感统计数据，时间段为 2002/01/01 00:00—2020/06/30 00:00，共 966 条数据，包括 2002 年至 2021 年美国疾病控制和预防中心每周数据，数值描述了患有流感疾病的患者与患者数量的比率。数据集使用.csv 格式保存，包含 322 个数据字段，具体如下：date：1 周颗粒度的时间戳、WEIGHTED ILI：加权比率、UNWEIGHTED ILI：非加权比率、AGE 0-4：0-4 岁患者数量、AGE 5-24：5-24 岁患者数量、ILITOTAL：患有流感疾病的患者总数、NUM. OF PROVIDERS：提供人数、OT：患者数量

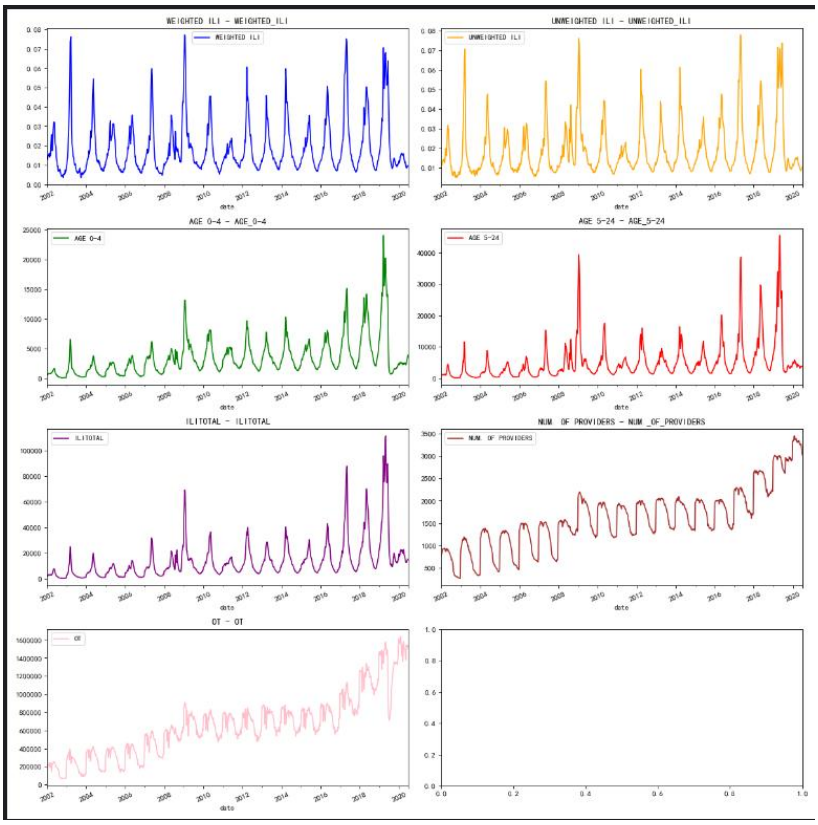

优势：标准 RNN 在反向传播长序列时，梯度会随着时间步指数衰减或爆炸，导致模型难以学习长期依赖。LSTM 的细胞状态通过直接传递和门控机制，允许梯度直接流过多个时间步，大大缓解了梯度消失问题。能够同时捕获长短期依赖，特别适合处理时间序列数据中的动态模式和复杂关系。

实际代码：

具体看代码 work7.py

数据预处理的功能由 preprocess_data 实现

LSTM 模型构建由 build_lstm_model、build_advanced_lstm_model、build_conv1d_lstm_model、conv_lstm_ConvLSTM2D_model、select_model 来实现 这里实现了多种 LSTM 模型可以用 select_model 进行选择训练。这里用第一个模型为例

```
Model: "sequential"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 lstm (LSTM)                 (None, 200)               166400

 dense (Dense)               (None, 1)                 201

=================================================================
Total params: 166,601
Trainable params: 166,601
Non-trainable params: 0
_________________________________________________________________
```

数据集创建用 create_dataset

数据集划分和标准化使用的是 keras 自带的 train_test_split 和 sklearn 的 MinMaxScaler

模型训练：这里使用 keras 自带的函数，定义了学习率衰减和早停机制。用的是 model.fit

训练过程记录功能是由 keras 的 model.fit 函数自带的

```
Epoch 2/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0033 - mae: 0.0432 - mape: 15.2415 - val_loss: 0.0181 - val_mae: 0.1197 - val_ma
Epoch 3/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0029 - mae: 0.0407 - mape: 13.9322 - val_loss: 0.0131 - val_mae: 0.0947 - val_ma
Epoch 4/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0025 - mae: 0.0371 - mape: 12.8702 - val_loss: 0.0109 - val_mae: 0.0812 - val_ma
Epoch 5/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0024 - mae: 0.0356 - mape: 11.6901 - val_loss: 0.0108 - val_mae: 0.0797 - val_ma
Epoch 6/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0023 - mae: 0.0342 - mape: 11.4193 - val_loss: 0.0090 - val_mae: 0.0711 - val_ma
Epoch 7/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0022 - mae: 0.0339 - mape: 11.1300 - val_loss: 0.0166 - val_mae: 0.1098 - val_ma
Epoch 8/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0021 - mae: 0.0334 - mape: 11.1294 - val_loss: 0.0144 - val_mae: 0.1042 - val_ma
Epoch 9/100
20/20 [==============================] - 0s 10ms/step - loss: 0.0023 - mae: 0.0355 - mape: 11.3893 - val_loss: 0.0105 - val_mae: 0.0779 - val_ma
```

预测结果

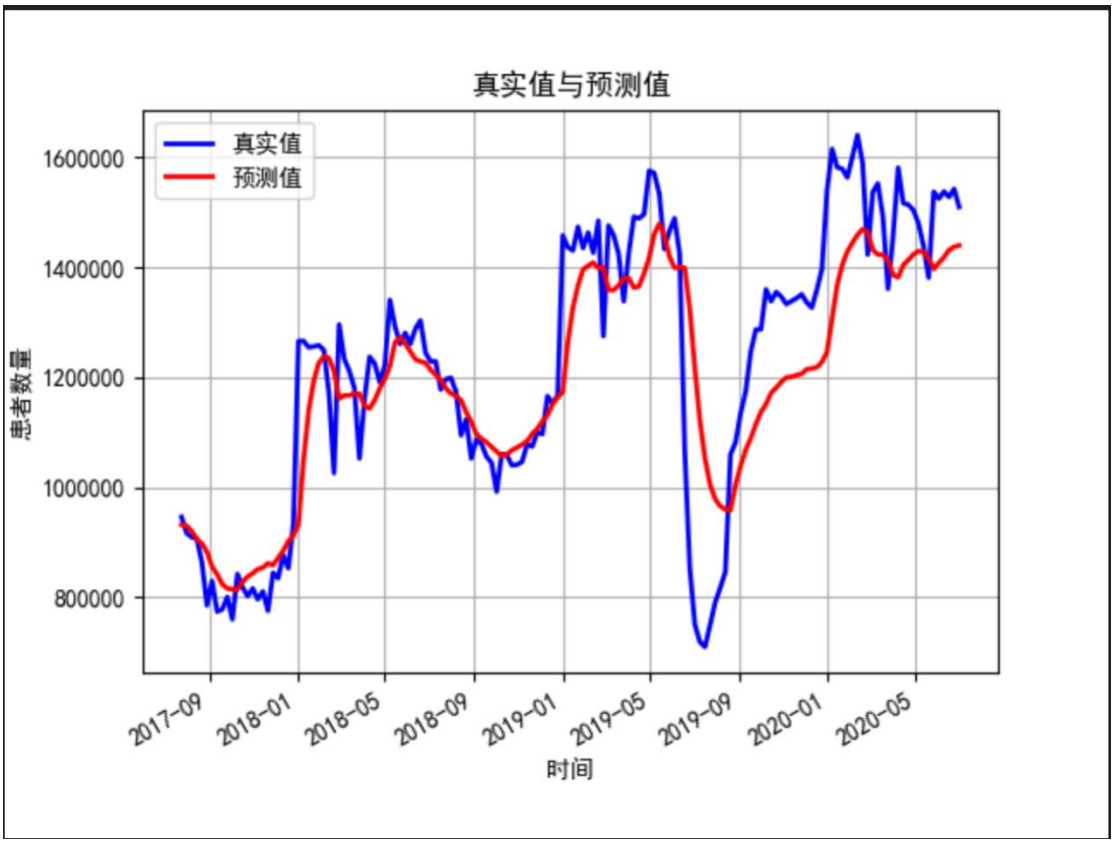

训练图表

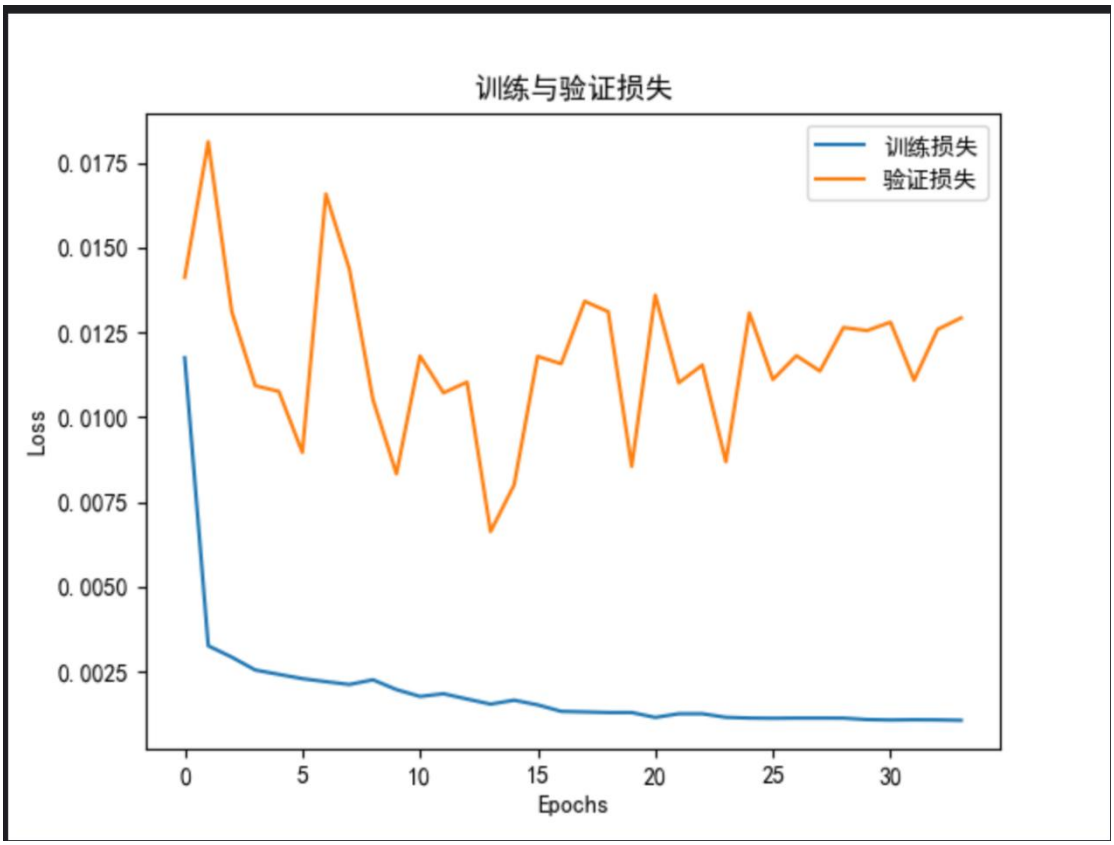

模型分析：目测有拟合，模型过于简单，要增加模型的复杂程度。

改进模型：

Layer (type)	Output Shape	Param #
bidirectional (Bidirectional)	(None, 200, 128)	36864
dropout (Dropout)	(None, 200, 128)	0
lstm_1 (LSTM)	(None, 200, 64)	49408
dropout_1 (Dropout)	(None, 200, 64)	0
lstm_2 (LSTM)	(None, 32)	12416
dropout_2 (Dropout)	(None, 32)	0
dense (Dense)	(None, 64)	2112
dropout_3 (Dropout)	(None, 64)	0
dense_1 (Dense)	(None, 1)	65

训练图表：

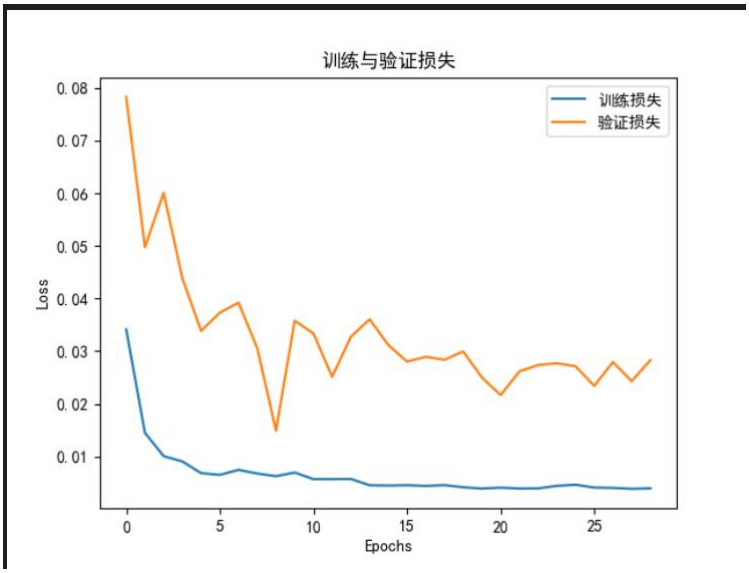

预测结果

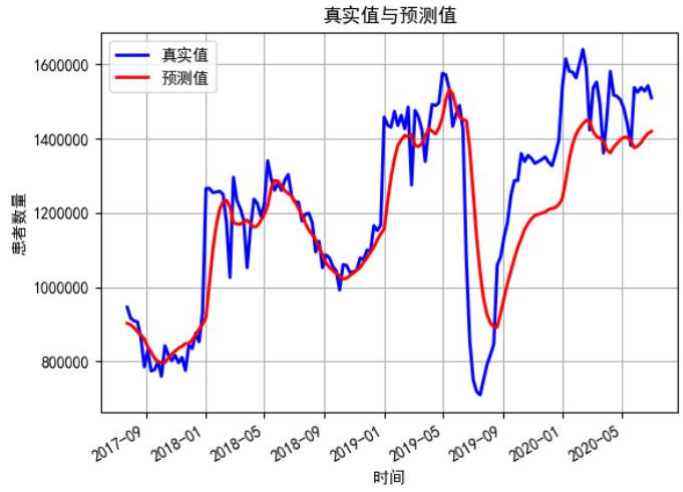

结果分析：模型训练过程趋于稳定 验证集的损失在降低，拟合程度在降低，因为模型的复杂程度提高，训练过程逐渐趋于稳定状态。

总体分析：数据的总体趋势是对的，但是很多点的仍然不准确。仍需对模型继续改进。

八、基于迁移学习实现一个图像分类任务，例如：使用预训练模型（如 ResNet、VGG）对新的小型图像数据集（如猫狗分类）进行分类。

这里我选择用 resnet32 来训练，因为 resnet 的的残差结构通过跳跃连接直接传递信息，具有较少的参数和较低的计算需求，非常适合中小型数据集和有限的计算资源。

迁移学习是一种机器学习方法，它将一个任务上训练得到的知识应用到另一个相关任务上。通常情况下，迁移学习通过使用在大型数据集（如 ImageNet）上预训练的模型，并将其应用于新的、数据较少的任务上，显著提高新任务的学习效果。

迁移学习非常适合数据量较小的场景，因为预训练模型已经在大量数据上学习了有效的特征，可以有效地帮助新任务，即使新任务的数据较少。

当目标任务的数据样本较少时，直接训练一个深度学习模型往往会导致过拟合。而迁移学习能够有效避免这一问题，因为预训练模型已经在大规模数据上学到了一些通用的特征。

这里选择的数据集是 CIFAR-10，keras2 目前可以直接加载 CIFAR-10 的数据，但是每次要进行在线下载，所以我直接本地读取了数据。

这里还是用 keras2 来进行编写代码。

详细代码见 work8.py

数据加载和预处理代码在 load_and_preprocess_cifar10 函数里。

这里的模型构建使用的是 resnet-32 的模型。

Keras 没有预训练好的 resnet-32 的模型，所以要先写残差模块的函数 residual_block。

之后再用 residual_network 函数构建 resnet 网络，模型的微调过程，这里对优化器进行微调，来观察模型的表现。

模型结构为：

第一层（输入卷积层）：1 层。

每个阶段：每个残差块由 2 层卷积构成，因此一个残差块有 2 层卷积，多个残差块的总层数为 2 * 残差块数。

在 resnet-32 中，第一阶段有 5 个残差块，因此有 5 * 2 = 10 层卷积。

第二阶段有 5 个残差块，因此也是 5 * 2 = 10 层卷积。

第三阶段有 5 个残差块，也是 5 * 2 = 10 层卷积。

全连接层：1 层。

计算总层数

输入卷积层：1 层

每个阶段的残差块：每个残差块有 2 层卷积，堆叠 5 个残差块时，共有 5 * 2 = 10 层卷积

最终的全连接层：1 层

因此，ResNet-32 的总层数为：

1（输入卷积层）

10（第一阶段的 5 个残差块，每个残差块有 2 层卷积）

10（第二阶段的 5 个残差块，每个残差块有 2 层卷积）

10（第三阶段的 5 个残差块，每个残差块有 2 层卷积）

1（全连接层）

总层数 = 1 + 10 + 10 + 10 + 1 = 32 层

ResNet-32 的层数为 32 层

这里使用的优化器有：sgd、adam 和 adamw。

第一次训练使用 sgd 的优化器进行。

训练时间是：15.94 分钟

```
Epoch 43/50
389/390 [============================>.] - ETA: 0s - loss: 0.5325 - accuracy: 0.8972Restoring model weights from the end of the best epoch: 33.
390/390 [==============================] - 11s 28ms/step - loss: 0.5329 - accuracy: 0.8971 - val_loss: 1.1540 - val_accuracy: 0.7483 - lr: 0.100
Epoch 43: early stopping
Training time: 10.34 minutes
313/313 [==============================] - 1s 2ms/step
```

由于写了早停机制，在训练模型最优的情况下停止训练。

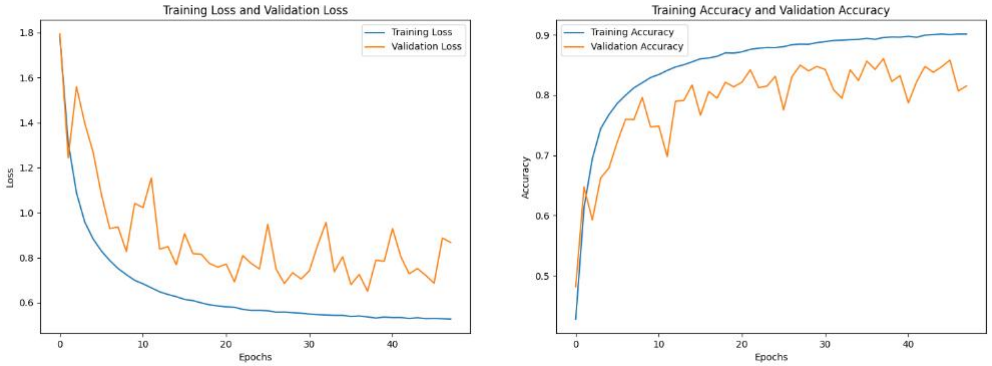

这是训练过程中的训练 ac 和 loss 以及测试的 ac 和 loss，发现测试的 ac 和 loss 是不稳定的下降，并且在训练快结束时，发现 loss 有回升的情况，ac 有下降的情况，并且写的 scheduler 的函数并没有用，是因为 epoch 数不到，以后要增加 epoch 的数量，以及调低 lr 的数值，进行微调，使训练过程更加稳定。

随机抽取 10 个结果进行预测，发现在船和汽车的预测会出现问题，应该提升模型分类程度，或者继续增加残差块，比如用 resnet50.

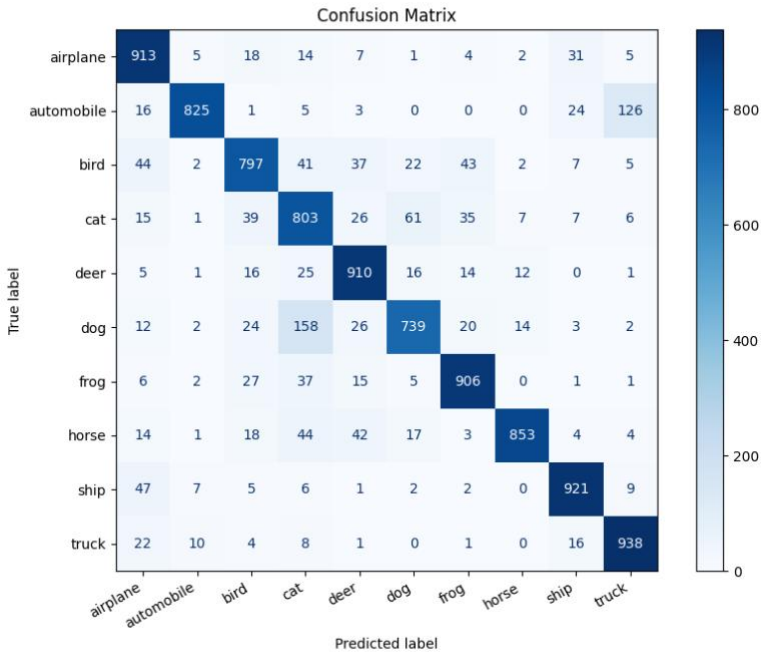

这是混淆矩阵图，其中可以发现分类出现有问题的数量大多数都是猫狗和汽车和卡车之间的分类，这是接下来要关注的优化问题。

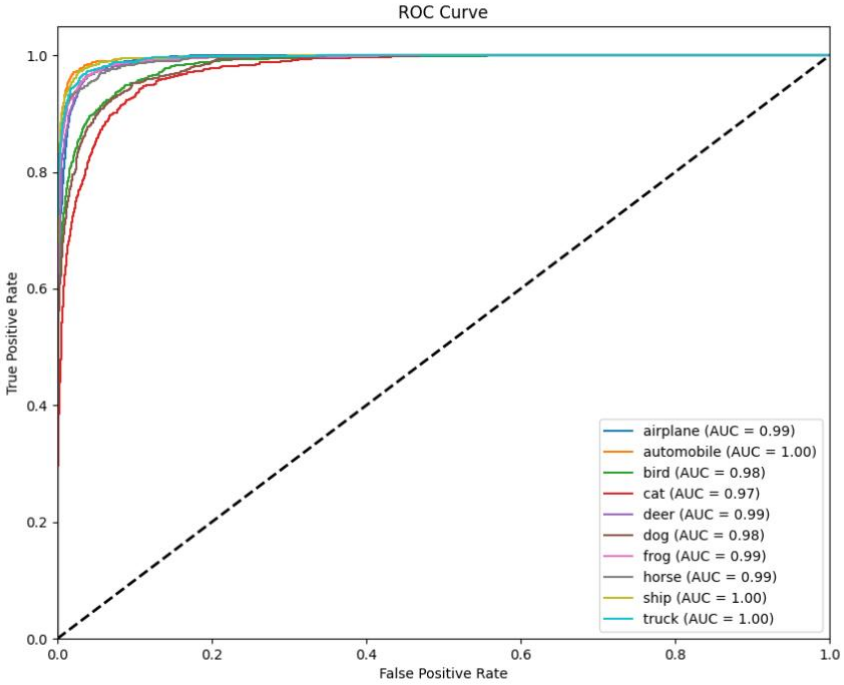

这是 ROC 曲线的结果，从图中可以看到，automobile、ship 和 truck 的 AUC 值为 1.00，这意味着这些类别的分类模型在所有阈值下都能区分正例和负例。

而 cat 类别的 AUC 值最低，为 0.97，虽然仍然是一个很高的值，但相对其他类别来说，其分类性能略差。

因为并没有选择更为复杂的模型，所以最终的结果，并不是太完美，但是更复杂的模型需要更好的算力进行计算，所以优化方向注重在优化器上是目前比较好的选择。

数据增强已经写了，所以就不作为优化方向的选择了。

接下来对优化器进行改变，这里举例使用 adam，并且因为 adam 的自适应能力，callback 里就不会添加 scheduler 来修改 lr 的值。

训练时间为：6.9 分钟

```
Epoch 38/50
390/390 [==============================] - ETA: 0s - loss: 0.4452 - accuracy: 0.9083Restoring model weights from the end of the best epoch: 28.
390/390 [==============================] - 11s 27ms/step - loss: 0.4452 - accuracy: 0.9083 - val_loss: 0.7028 - val_accuracy: 0.8371
Epoch 38: early stopping
Training time: 6.90 minutes
```

由于写了早停机制，在训练模型最优的情况下停止训练。

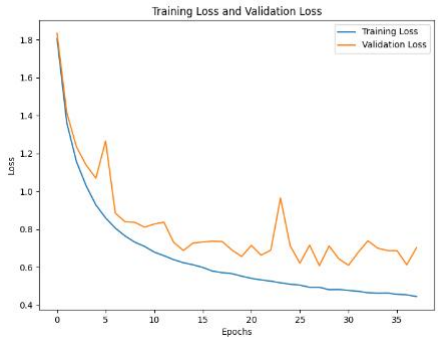

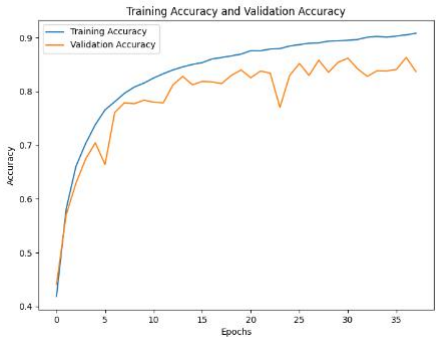

训练和测试的 loss 和 ac 曲线，相对于 sgd 的来说，更加稳定，并且最高精度要比 sgd 高，训练时间更短。

此时再进行 10 次的预测，并且有重复与上次 sgd 的预测，这次分类成功，证明优化的方向是可行的。

左图是 sgd 优化器的预测结果 右图是 adam 优化器的预测结果

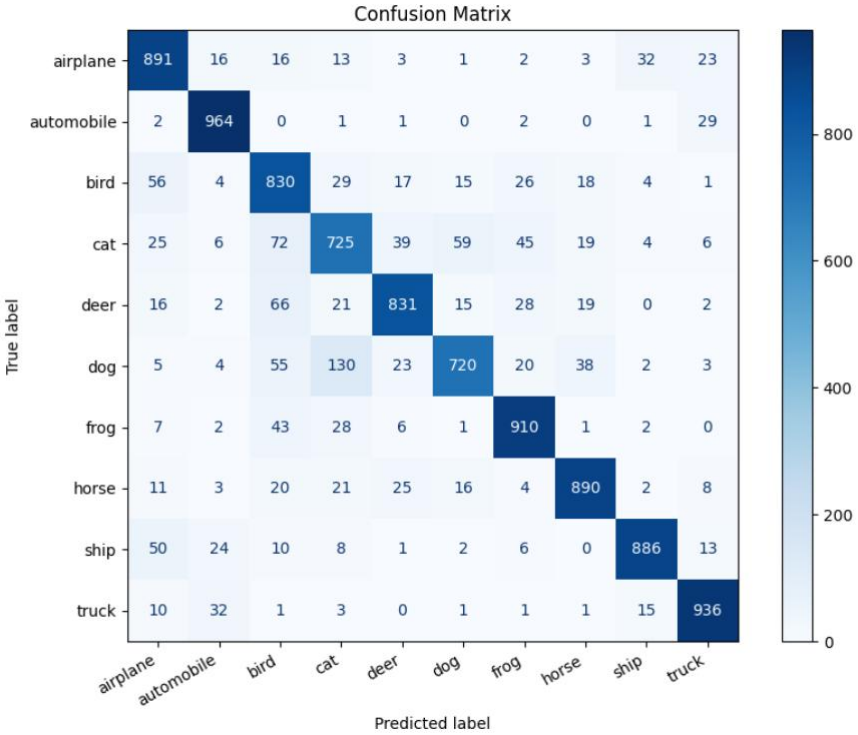

此次的预测结果混淆矩阵，相比上次的混淆矩阵，算是解决了汽车和卡车的分类问题，猫狗的分类是由改善，但是还是有问题，认为需要进一步的提升精度，因为猫狗的形态上相似，所以需要在更高的精度上进行识别。

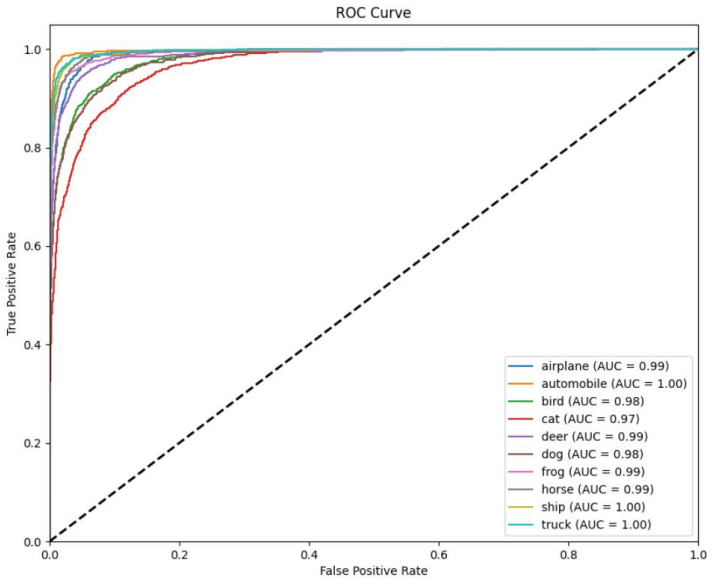

这是 ROC 分辨率图，观察发现 sgd 和 adam 的图差不多，并没有

很明显的差距，但是 adam 的时间更少，因为其自适应学习率的特性而表现出更快的收敛速度和更好的稳定性。

后面的优化方向，我认为是应该在模型的结构上进行，例如，将 resnet32 改成 resnet50，增加残差结构，增加深度，改进卷积层，或者引入注意力机制，比如 SE 模块等， 使用超参数，利用自动化超参数优化算法，比如贝叶斯优化、Hyperband、SMBO 等。